

İSTANBUL TOPKAPI ÜNİVERSİTESİ

DERİN ÖĞRENME FİNAL ÖDEVİ

YOLOv8 Tabanlı Derin Öğrenme Yaklaşımlarıyla Beyin Tümörü Tespiti

Öğrenci: Ali Kemal Kefelioğlu

Ders: Derin Öğrenme

Tarih: Haziran 2026

GitHub: <https://github.com/akkefelioglu/derin-ogrenme>

1. Proje Açıklaması

Bu projede, Ultralytics tarafından sağlanan **Brain Tumor Detection** veri seti kullanılmıştır. Veri seti, YOLOv8 nesne tespiti modellerini eğitmek üzere yapılandırılmış olup manyetik rezonans (MR) görüntüleri içermektedir. Görüntüler iki sınıfa ayrılmıştır: tümör bulunan (pozitif) ve bulunmayan (negatif). Amaç, yeni MR görüntülerinde tümör varlığını YOLOv8 modeliyle otomatik olarak tespit etmektir.

Veri Seti Bağlantısı:

<https://github.com/ultralytics/assets/releases/download/v0.0.0/brain-tumor.zip>

Dokümantasyon:

<https://docs.ultralytics.com/tr/datasets/detect/brain-tumor/>


2. Proje Hedefi

- YOLOv8 modeliyle MR görüntülerinden beyin tümörü tespiti yapmak
- Model başarımını standart metriklerle değerlendirmek
- Veri artırma ve transfer öğrenme stratejilerini uygulamak
- Tespit sonuçlarını görselleştirmek ve modelin güvenilirliğini analiz etmek

3. Veri Seti Yapısı

Ultralytics tarafından sağlanan Brain Tumor Detection veri seti, toplam 1116 MR görüntüsünden oluşmaktadır. Veri seti, eğitim ve doğrulama olmak üzere iki alt kümeye ayrılmıştır.

Alt Küme	Görüntü Sayısı	Açıklama
Eğitim (train)	893	Model eğitimi için kullanılan görüntüler
Doğrulama (valid)	223	Model değerlendirmesi için kullanılan görüntüler




Şekil 1: Eğitim veri setinden örnek MR görüntüleri ve etiketleri.

3.1. Sınıf Bilgileri

Sınıf ID	Sınıf Adı	Açıklama
0	Negatif	Beyin tümörü bulunmayan MR görüntüleri
1	Pozitif	Beyin tümörü bulunan MR görüntüleri

Veri seti YOLO formatında etiketlenmiş olup, her görüntü için bir .txt etiket dosyası bulunmaktadır. Etiket dosyalarında sınıf ID'si ve bounding box koordinatları (normalize edilmiş xywh formatında) yer almaktadır.



Şekil 2: Eğitim ve doğrulama setlerindeki sınıf dağılımı grafiği.

4. Yöntem

4.1. Model Mimarisi: YOLOv8

YOLOv8 (You Only Look Once v8), Ultralytics tarafından geliştirilen son nesil gerçek zamanlı nesne tespiti modelidir. YOLO ailesi, nesne tespiti

tek bir ileri geçişte (single forward pass) gerçekleştirerek hem hız hem de doğruluk açısından üstün performans sunar.

Bu projede **YOLOv8n (Nano)** varyantı tercih edilmiştir. Nano model, en hafif YOLOv8 modelidir ve 3.2M parametre içerir. Küçük veri setlerinde overfitting riskini azaltması ve hızlı eğitim süresi sunması nedeniyle tercih edilmiştir.

4.2. Transfer Öğrenme

Transfer öğrenme stratejisi uygulanarak, COCO veri seti üzerinde önceden eğitilmiş `yolov8n.pt` ağırlıkları başlangıç noktası olarak kullanılmıştır. Bu yaklaşım sayesinde model, genel görüntü özelliklerini (kenarlar, dokular, şekiller) önceden öğrenmiş durumda başlar ve beyin tümörü tespitine özgü özellikleri daha az veri ile öğrenebilir.

Transfer Öğrenmenin Avantajları:

- Daha az eğitim verisi ile yüksek performans
- Daha hızlı yakınsama (convergence)
- Düşük seviyeli özelliklerin yeniden kullanılması
- Overfitting riskinin azaltılması

4.3. Veri Artırma (Data Augmentation)

YOLOv8, eğitim sırasında otomatik olarak çeşitli veri artırma teknikleri uygular. Bu teknikler, modelin genelleme kapasitesini artırarak overfitting'i önler:

Teknik	Açıklama
Mozaik (Mosaic)	4 farklı görüntüyü birleştirerek çeşitlilik artırır
Ölçekleme (Scale)	Görüntü boyutunu rastgele değiştirir ($\pm 50\%$)
Yatay Çevirme (Flip)	Görüntüyü yatay ekseninde çevirir (%50 olasılıkla)
HSV Augmentation	Renk tonu, doygunluk ve parlaklık değişiklikleri uygular
Döndürme (Rotation)	Görüntüyü rastgele açılarla döndürür
Kırpma (Crop)	Görüntünün rastgele bölgelerini kırpar

4.4. YAML Yapılandırması

```
path: /content/datasets/brain-tumor
train: train/images
val: valid/images

names:
  0: negative
  1: positive
```

4.5. Eğitim Parametreleri

Parametre	Değer	Açıklama
Model	yolov8n.pt	YOLOv8 Nano, önceden eğitilmiş ağırlıklar
Epoch	50	Toplam eğitim döngüsü sayısı
Image Size	640×640	Giriş görüntü boyutu
Batch Size	16	Her iterasyondaki görüntü sayısı
Optimizer	SGD	Stochastic Gradient Descent (varsayılan)
Learning Rate	0.01	Başlangıç öğrenme oranı
Patience	10	Early stopping sabır değeri

4.6. Eğitim Komutu

```
yolo detect train data=brain-tumor.yaml model=yolov8n.pt epochs=50
imgsz=640
```

5. Değerlendirme Metrikleri

Model performansı aşağıdaki standart nesne tespiti metrikleri kullanılarak değerlendirilmiştir:

5.1. Metrik Tanımları


Metrik	Tanım
Precision (Kesinlik)	Doğru pozitif tahminlerin tüm pozitif tahminlere oranı. $TP / (TP + FP)$
Recall (Duyarlılık)	Doğru pozitif tahminlerin tüm gerçek pozitiflere oranı. $TP / (TP + FN)$
mAP@0.5	IoU eşiği 0.5'te ortalama hassasiyet. Tahmin kutusu ile gerçek kutunun en az %50 örtüşmesi gerekir.
mAP@0.5:0.95	IoU eşiği 0.5'ten 0.95'e kadar 0.05 aralıklarla hesaplanan ortalama mAP. Daha kapsamlı bir metrik.
Karışıklık Matrisi	Modelin doğru ve yanlış sınıflandırmalarını gösteren tablo.

5.2. Model Sonuçları

YOLOv8n modelinin 50 epoch eğitim sonrası doğrulama seti üzerindeki performans metrikleri:

Model Başarımı: Google Colab'da (Tesla T4 GPU) gerçekleştirilen eğitim sonucunda elde edilen değerlendirme metrikleri aşağıdadır.


Metrik	Değer
Precision (Kesinlik)	0.4523
Recall (Duyarlılık)	0.8039
mAP@0.5	0.4901
mAP@0.5:0.95	0.3519



Şekil 3: Eğitim süreci boyunca loss (kayıp) ve metriklerin değişimi.

5.3. Karışıklık Matrisi Analizi

Karışıklık matrisi, modelin sınıflandırma performansını detaylı olarak gösterir. Matrisin köşegen elemanları doğru tahminleri, köşegen dışı elemanlar ise yanlış tahminleri temsil eder. Eğitim sonrası elde edilen karışıklık matrisi, notebook çıktısında görselleştirilmiştir.



Şekil 4: Doğrulama seti üzerinde elde edilen Karışıklık Matrisi (Confusion Matrix).

5.4. Modelin Güvenilirliği Analizi

Modelin güvenilirliği çeşitli açılardan değerlendirilmiştir:

- **F1-Confidence Eğrisi:** Farklı güven eşik değerlerinde modelin F1 skorunu gösterir. Optimum güven eşiği, F1 skorunun en yüksek olduğu


noktadır.

- **Precision-Recall Eğrisi:** Kesinlik ve duyarlılık arasındaki dengeyi gösterir. Eğri altında kalan alan (AUC) ne kadar büyükse model o kadar başarılıdır.
- **Precision-Confidence Eğrisi:** Güven eşiği arttıkça kesinliğin nasıl değiştiğini gösterir. Yüksek güven eşiklerinde kesinliğin artması modelin güvenilir tahminler yaptığını gösterir.
- **Recall-Confidence Eğrisi:** Güven eşiği arttıkça duyarlılığın nasıl değiştiğini gösterir. Düşük güven eşiklerinde bile yüksek recall, modelin tümörleri kaçırmadığını gösterir.

Tıbbi görüntü analizinde **yüksek recall** (duyarlılık) değeri kritik öneme sahiptir çünkü bir tümörü kaçırmak (yanlış negatif), yanlış alarm vermekten (yanlış pozitif) çok daha tehlikelidir. Bu nedenle modelin güven eşiği, recall değerini maksimize edecek şekilde ayarlanmalıdır.

5.5. Örnek Tahminler (Inference)

Eğitilen model, daha önce görmediği doğrulama seti (validation set) görüntüleri üzerinde test edilmiş ve başarılı bir şekilde tümörleri tespit edebildiği görülmüştür.



Şekil 5: Eğitilmiş YOLOv8n modelinin MR görüntüleri üzerindeki tespit örnekleri.

6. Sonuç ve Tartışma

Bu projede, YOLOv8n modeli kullanılarak beyin tümörü tespiti başarıyla gerçekleştirilmiştir. COCO veri seti üzerinde önceden eğitilmiş ağırlıklar ile transfer öğrenme stratejisi uygulanmış, bu sayede 893 eğitim görüntüsü ile etkili bir model elde edilmiştir.

YOLOv8'in sağladığı otomatik veri artırma teknikleri (mozaik, ölçekleme, çevirme vb.) modelin genelleme kapasitesini artırmış ve overfitting riskini azaltmıştır.

Model, MR görüntülerinde tümör varlığını ve konumunu bounding box ile tespit edebilmekte, bu da klinisyenlere hızlı ve otomatik bir ön tarama aracı sunma potansiyeli taşımaktadır.

6.1. İyileştirme Önerileri

- Daha büyük YOLOv8 modelleri (yolov8s, yolov8m) ile karşılaştırma yapılabilir
- Epoch sayısı artırılarak (100-200) model performansı iyileştirilebilir
- Farklı öğrenme oranları ve optimizier'lar denenebilir
- Veri setine ek MR görüntüleri eklenerek eğitim verisi zenginleştirilebilir
- Ensemble yöntemleri ile birden fazla modelin tahminleri birleştirilebilir

7. Kaynaklar

1. Ultralytics. (2023). *Brain Tumor Detection Dataset*.
<https://docs.ultralytics.com/datasets/detect/brain-tumor/>
2. Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8*.
<https://github.com/ultralytics/ultralytics>
3. Redmon, J., et al. (2016). *You Only Look Once: Unified, Real-Time Object Detection*. CVPR.
4. Pan, S. J., & Yang, Q. (2010). *A Survey on Transfer Learning*. IEEE Transactions on Knowledge and Data Engineering.